Analyse d'un jeu de données réel

Fabien Haury

2022-04-30

- 1 Librairies
- 2 Données manquantes
 - o 2.1 Jeu de données PhD_v1
 - 2.2 Jeu de données PhD_v2
 - o 2.3 Visualisation des données manquantes
- 3 Problèmes
 - 3.1 Problèmes soutenances
 - o 3.2 Problème homonyme Cecile Martin
- 4 Outliers
 - 4.1 Outliers director
- 5 Résultats préliminaires
 - o 5.1 Langues
- 6 SQL
- 7 Travail en bonus
 - 7.1 Heatmap des données manquantes
 - 7.2 Problème Genre/Discipline/Langue
 - 7.3 Webscraping

1 Librairies

library(plyr)

library(tidyverse)

library(lubridate)

library(naniar)

library(scales)

library(ggsci)

library(GGally)

library(ggthemes)

... (ggtheines

library(lemon)
library(rvest)

plyr pour appliquer le paradigme «split-apply-combine».

tidyverse contient tidyr, dplyr et ggplot2 pour la manipulation et visualisation des données.

naniar pour visualiser les données manquantes.

lubridate pour la gestion des formats de date.

scales pour modifier les formats d'échelles des graphiques.

ggsci pour différents thèmes de graphique.

ggthemes donne accès à des thèmes supplémentaires pour ggplot2

lemon donne accès à des fonction suppémentaires pour changer subtilement des aspects de ggplot2 rvest pour le web scraping.

2 Données manquantes

2.1 Jeu de données PhD_v1

2.1.1 Import du jeu de données

```
these_v1 <- read_csv("jeux_de_donnees/PhD_v1.csv")
head(these_v1)
```

```
## # A tibble: 6 x 1

## `Auteur;Identifiant auteur;Titre;Directeur de these;Directeur de these (nom ~`

## <chr>
## 1 "Saeed Al marri;;Le credit documentaire et l'onopposabilite des exceptions;Ph~

## 2 "Andrea Ramazzotti;174423705;Application de la PGD a la resolution de problem~

## 3 "OLIVIER BODENREIDER;;Conception d'un outil informatique d'etude des cinetiqu~

## 4 "Emmanuel Porte;;Socio-histoire des politiques publiques en matiere sociale c~

## 5 "Arthur Devriendt;;LES TECHNOLOGIES DE L'INFORMATION ET DE LA COMMUNICATION E~

## 6 "Elmantsr Briak;;Integration forcee de l'afrique subsaharienne dans le proces~
```

```
dim(these_v1)
```

```
## [1] 446871 1

rm(these_v1)
```

La commande rm permet de supprimer la variable these_v1

2.2 Jeu de données PhD_v2

2.2.1 Import et préparation des données

```
these <- as_tibble(read_csv("jeux_de_donnees/PhD_v2.csv"))
these$`Date de soutenance` <- dmy(these$`Date de soutenance`)
these$`Publication dans theses.fr` <- dmy(these$`Publication dans theses.fr`)
these$`Mise a jour dans theses.fr` <- dmy(these$`Mise a jour dans theses.fr`)
these$Statut <- as.factor(these$Statut)
these$`Langue de la these` <- as.factor(these$`Langue de la these`)
these$`Accessible en ligne` <- as.factor(these$`Accessible en ligne`)
these$`Identifiant directeur` <- na_if(these$`Identifiant directeur`,"na")
```

2.2.2 Summary.

head(these)

```
## # A tibble: 6 x 18
## Auteur
                `Identifiant aut~` Titre `Directeur de ~` `Directeur de ~`
                <chr> <chr> <chr>
## <chr>
                                               <chr>
## 1 Saeed Al marri <NA>
                               "Le ~ Philippe Delebe~ Delebecque Phil~
## 2 Andrea Ramazzotti 174423705 "App~ Jean-Claude Gra~ Grandidier Jean~
## 3 OLIVIER BODENREIDER <NA>
                                          "Con~ Francois Kohler Kohler Francois
                                    "Soc~ Gilles Pollet Pollet Gilles
## 4 Emmanuel Porte <NA>
                                 "LES~ Gabriel Dupuy Dupuy Gabriel
## 5 Arthur Devriendt <NA>
                              "Int~ Edmond Jouve  Jouve Edmond
## 6 Elmantsr Briak <NA>
## # ... with 13 more variables: `Identifiant directeur` <chr>,
## # `Etablissement de soutenance` <chr>, `Identifiant etablissement` <chr>,
## # Discipline <chr>, Statut <fct>,
## # `Date de premiere inscription en doctorat` <chr>,
## # `Date de soutenance` <date>, Year <dbl>, `Langue de la these` <fct>,
## # `Identifiant de la these` <chr>, `Accessible en ligne` <fct>,
## # `Publication dans theses.fr` <date>, ...
```

glimpse(these)

```
## Rows: 447,644
## Columns: 18
                                <chr> "Saeed Al marri", "Andrea R~
## $ Auteur
## $ `Identifiant auteur`
                                  <chr> NA, "174423705", NA, NA, NA~
## $ Titre
                              <chr> "Le credit documentaire et ~
## $ `Directeur de these`
                                  <chr> "Philippe Delebecque", "Jea~
## $ `Directeur de these (nom prenom)` <chr> "Delebecque Philippe", "Gra~
                         <chr> "29561248", "715,441,511", ~
## $ `Identifiant directeur`
## $ `Etablissement de soutenance`
                                    <chr> "Paris 1", "Chasseneuil-du-~
                                  <chr> "27361802", "28024400", NA,~
## $ `Identifiant etablissement`
## $ Discipline
                                <chr> "Driot prive", "Mecanique d~
## $ Statut
                               <fct> enCours, enCours, soutenue,~
## $ `Date de premiere inscription en doctorat` <chr> "30-09-11", "01-10-12", NA,~
## $ `Date de soutenance`
                                    <date> NA, NA, 1993-01-01, NA, NA~
                               <dbl> NA, NA, 1993, NA, NA, 2008,~
## $ Year
## $ `Langue de la these`
                                   <fct> NA, NA, fr, NA, NA, NA, NA,~
                                    <chr> "s69480", "s98826", "1993NA~
## $ `Identifiant de la these`
## $ `Accessible en ligne`
                                    <fct> non, non, non, non, non, no~
                                   <date> 2012-01-26, 2013-11-22, 20~
## $ `Publication dans theses.fr`
## $ `Mise a jour dans theses.fr`
                                      <date> 2012-01-26, 2013-11-22, 20~
```

summary(these)

```
Directeur de these
   Auteur
              Identifiant auteur Titre
## Length:447644 Length:447644 Length:447644 Length:447644
## Class:character Class:character Class:character Class:character
## Mode :character Mode :character Mode :character Mode :character
##
##
##
##
## Directeur de these (nom prenom) Identifiant directeur
## Length:447644 Length:447644
                      Class :character
## Class :character
## Mode :character
                       Mode :character
##
##
##
##
## Etablissement de soutenance Identifiant etablissement Discipline
## Length:447644 Length:447644
                                     Length:447644
                    Class :character
## Class :character
                                        Class :character
## Mode :character
                    ##
##
##
##
             Date de premiere inscription en doctorat
##
     Statut
## enCours: 66329 Length: 447644
## soutenue:381315 Class:character
##
          Mode :character
##
##
##
## Date de soutenance Year Langue de la these
## Min. :1971-01-01 Min. :1971 fr :334404
## 1st Qu.:1994-01-01 1st Qu.:1994 en : 30942
## Median: 2004-01-01 Median: 2004 enfr: 10576
## Mean :2003-06-08 Mean :2003 fren : 4793
## 3rd Qu.:2012-06-25 3rd Qu.:2012 it : 634
## Max. :2020-07-07 Max. :2020 (Other): 2530
## NA's :56746 NA's :56746 NA's :63765
## Identifiant de la these Accessible en ligne Publication dans theses.fr
## Length:447644 non:347341 Min. :2006-04-13
## Class :character oui:100303 1st Qu.:2013-05-24
## Mode :character Median :2013-05-24
##
                        Mean :2014-11-09
##
                         3rd Qu.:2016-07-11
##
                         Max. :2020-07-08
##
## Mise a jour dans theses.fr
## Min. :2010-10-12
## 1st Qu.:2019-04-08
## Median: 2020-02-26
## Mean :2019-06-30
## 3rd Qu.:2020-03-08
## Max. :2020-07-08
## NA's :177
```

```
these %>%
summarise(across(everything(), n_distinct)) %>%
glimpse()
```

```
## Rows: 1
## Columns: 18
## $ `Directeur de these` <int> 159019
## $ `Directeur de these (nom prenom)` <int> 159021
## $ `Identifiant directeur` <int> 98907
## $ `Etablissement de soutenance` <int> 568
## $ `Identifiant etablissement` <int> 573
                   <int> 24263
<int> 2
## $ Discipline
## $ Statut
## $ `Date de premiere inscription en doctorat` <int> 4010
## $ `Date de soutenance` <int> 3992
                              <int> 45
## $ Year
## $ `Langue de la these`
                               <int> 206
## $ Langue de la triese

## $ `Identifiant de la these`

## $ `Accessible en ligne`

## $ `Publication dans theses.fr`

## $ `Mise a jour dans theses.fr`

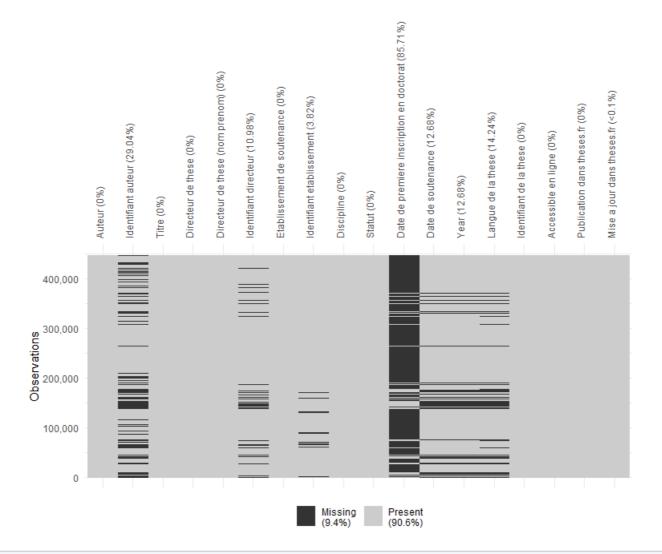
cint> 2634
```

2.3 Visualisation des données manquantes

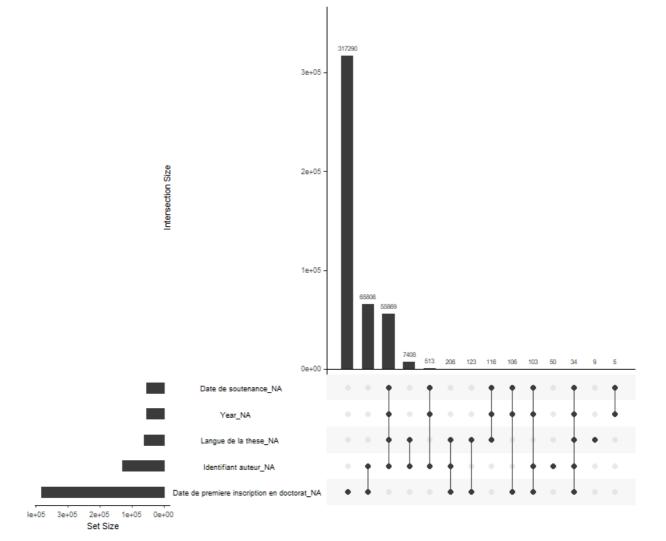
2.3.1 Préparation des données manquantes

2.3.2 Visualisation des données manquantes

```
# Visualisation donnees manquantes
vis_miss(these, warn_large_data = FALSE) +
scale_y_continuous(labels = comma) +
theme(axis.text.x = element_text(angle = 90))
```



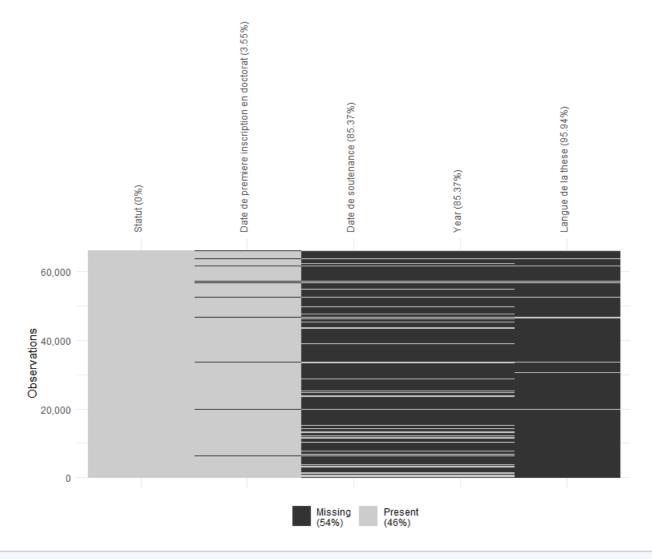
gg_miss_upset(these)



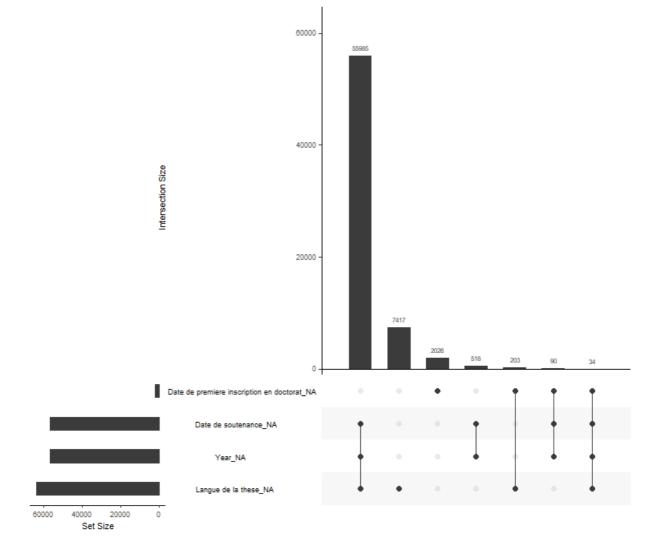
Visualisation statut enCours

vis_miss(these_NA_encours, warn_large_data = FALSE) + scale_y_continuous(labels = comma) +

 $theme(\underbrace{axis.text.x} = element_text(\underbrace{angle} = 90))$



gg_miss_upset(these_NA_encours)

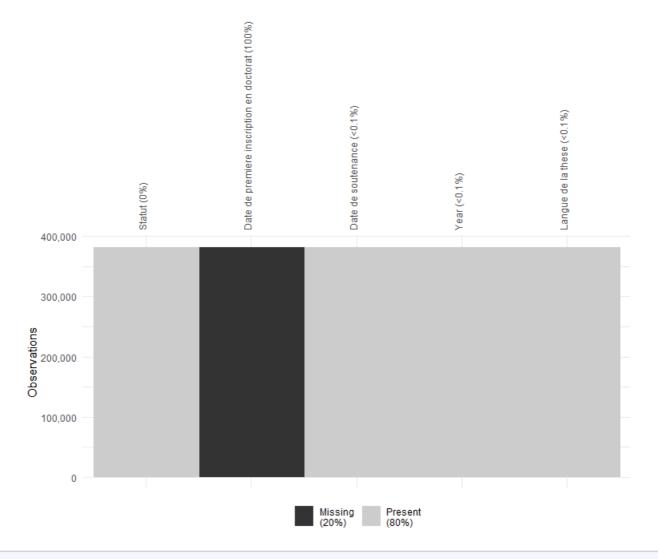


Visualisation statut soutenue

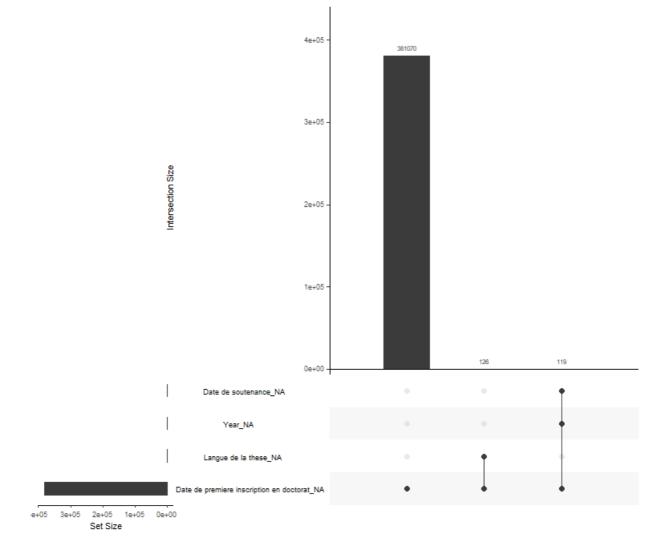
vis_miss(these_NA_soutenue, warn_large_data = FALSE) +

scale_y_continuous(labels = comma) +

 $theme(\underbrace{axis.text.x} = element_text(\underbrace{angle} = 90))$



gg_miss_upset(these_NA_soutenue)



3 Problèmes

3.1 Problèmes soutenances

3.1.1 Préparations des données

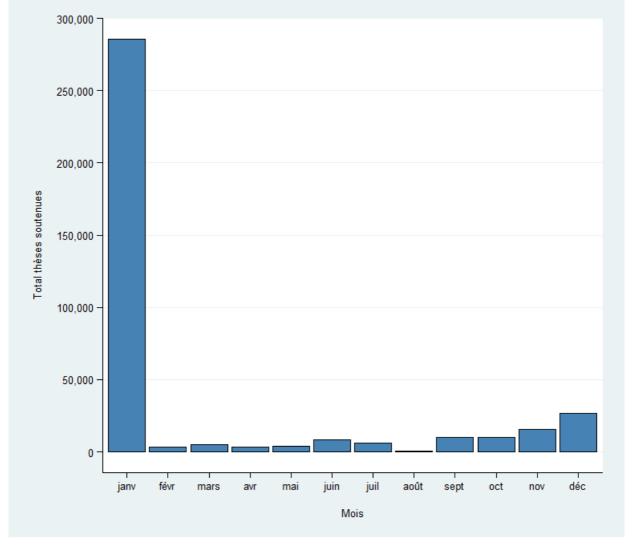
```
these_soutenance <- these %>% select(Year, `Date de soutenance`)
these_soutenance <- these_soutenance %>%
mutate(month = as.factor(month(`Date de soutenance`, label = TRUE)),
day = as.factor(day(`Date de soutenance`)))
```

Selection des variables cibles et création de nouvelles colonnes month et day pour plus de lisibilité dans le code suivant.

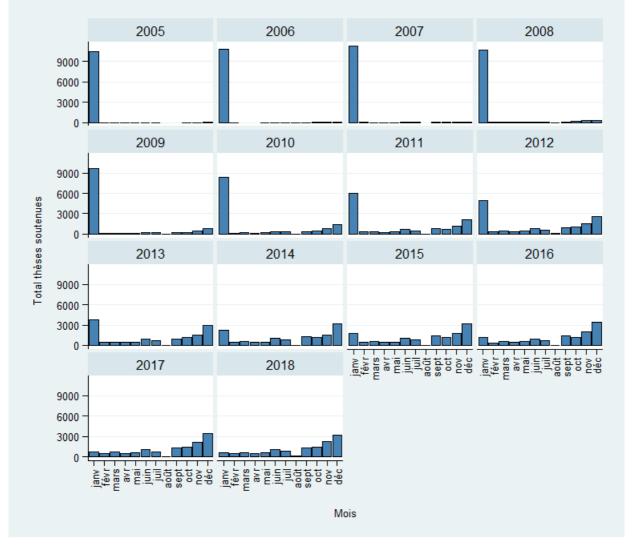
3.1.2 Préparation des tables intermédiaires.

```
# full_join pour la distribution des pourcentages moyens de soutenance par mois avec errorbar
# Sans filtrer le 1 Janvier
these_soutenance_count_year <- these_soutenance %>%
 filter(Year > 2004 & Year < 2019) %>%
 count(Year) %>%
 rename(total year = n)
these_soutenance_year_month <- these_soutenance %>%
 filter(Year > 2004 & Year < 2019) %>%
 count(Year, month) %>%
 rename(total\_month = n)
these_soutenance_full <- full_join(these_soutenance_count_year,
                         these_soutenance_year_month,
                         by = "Year") %>%
 mutate(freq = total_month / total_year) %>%
 drop na()
# Avec filtre sur le 1 Janvier
these_soutenance_count_year_no_first <- these_soutenance %>%
 filter(day != "1" & Year > 2004 & Year < 2019) %>%
 count(Year) %>%
 rename(total\_year = n)
these_soutenance_year_month_no_first <- these_soutenance %>%
 filter(day != "1" & Year > 2004 & Year < 2019) %>%
 count(Year, month) %>%
 rename(total month = n)
these_soutenance_full_no_first <- full_join(these_soutenance_count_year_no_first,
                    these_soutenance_year_month_no_first,
                    by = "Year") %>%
 mutate(freq = total_month / total_year) %>%
 drop_na()
# full_join pour l'evolution des frequences des defenses de theses par annees au premier janvier
these_soutenance_count_year <- these_soutenance %>%
 count(Year) %>%
 rename(total year = n)
these_soutenance_count_janv <- these_soutenance %>%
 filter(month == "janv" & day == "1") %>%
 group by(Year) %>%
 count(Year) %>%
 rename(total\_janv = n)
these_soutenance_year_janv <- full_join(these_soutenance_count_year,
                         these_soutenance_count_janv, by = "Year") %>%
 mutate(freq = total_janv / total_year)
```

3.1.3 Visualisations



```
# facet_wrap month~year
these_soutenance %>%
filter(Year > 2004 & Year < 2019) %>%
count(Year, month) %>%
ggplot(aes(month, n)) +
geom_col(fill = "steelblue", color = "black") +
facet_wrap( ~ Year) +
scale_x_discrete(guide = guide_axis(angle = 90)) +
labs(x = "\nMois",
    y = "Total thèses soutenues\n") +
theme_stata() +
theme(axis.text.y = element_text(angle = 0))
```



```
# Distribution des pourcentages moyens de soutenance par mois avec errorbar

# Avec 1 Janvier

these_soutenance_full %>%

ddply(~month, summarise, mean = mean(freq, na.rm = TRUE), sd = sd(freq, na.rm = TRUE)) %>%

ggplot(aes(month, mean)) +

geom_col(fill = "steelblue", color = "black") +

geom_errorbar(aes(ymin = mean - sd, ymax = mean + sd)) +

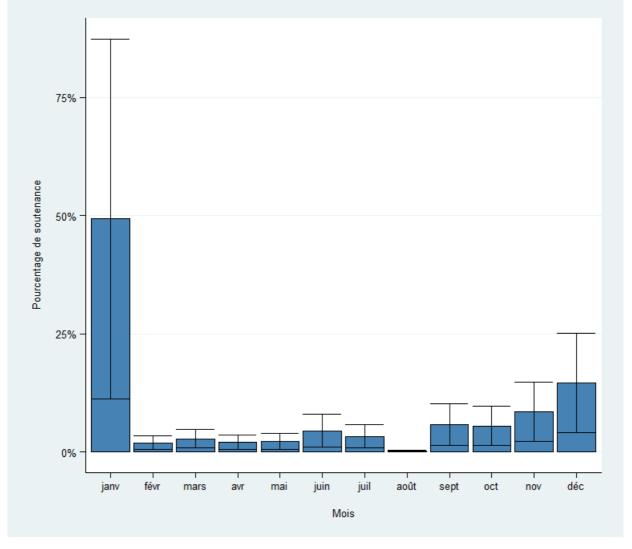
scale_y_continuous(labels = percent_format()) +

labs(x = "\nMois",

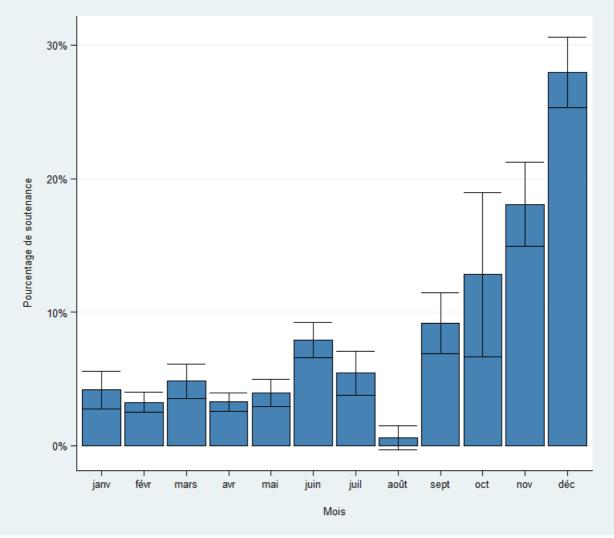
y = "Pourcentage de soutenance\n") +

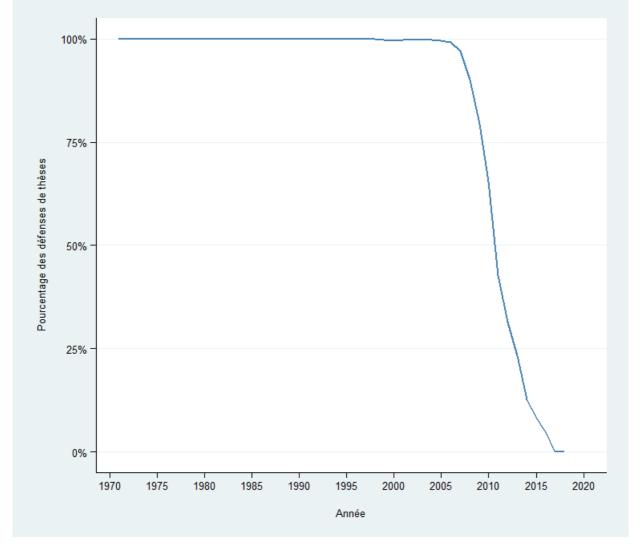
theme_stata() +

theme(axis.text.y = element_text(angle = 0))
```



```
# Sans 1 Janvier
these_soutenance_full_no_first %>%
ddply(~month, summarise, mean = mean(freq, na.rm = TRUE), sd = sd(freq, na.rm = TRUE)) %>%
ggplot(aes(month, mean)) +
geom_col(fill = "steelblue", color = "black") +
geom_errorbar(aes(ymin = mean - sd, ymax = mean + sd)) +
scale_y_continuous(labels = percent_format()) +
labs(x = "\nMois",
    y = "Pourcentage de soutenance\n") +
theme_stata() +
theme(axis.text.y = element_text(angle = 0))
```





3.2 Problème homonyme Cecile Martin

3.2.1 Import et préparation des données

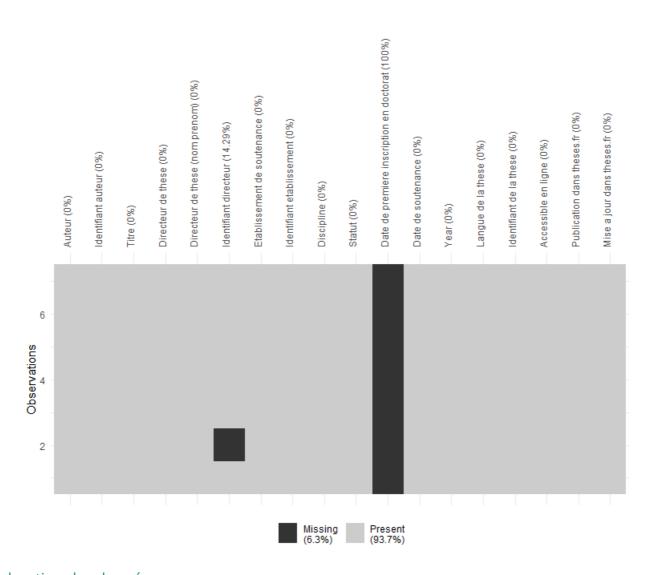
```
these_cecile_martin <- these %>%
filter(str_detect(Auteur, "Cecile Martin")) %>%
slice(-c(4,6, 8, 9, 12))

glimpse(these_cecile_martin %>%
summarise(across(everything(), n_distinct)))
```

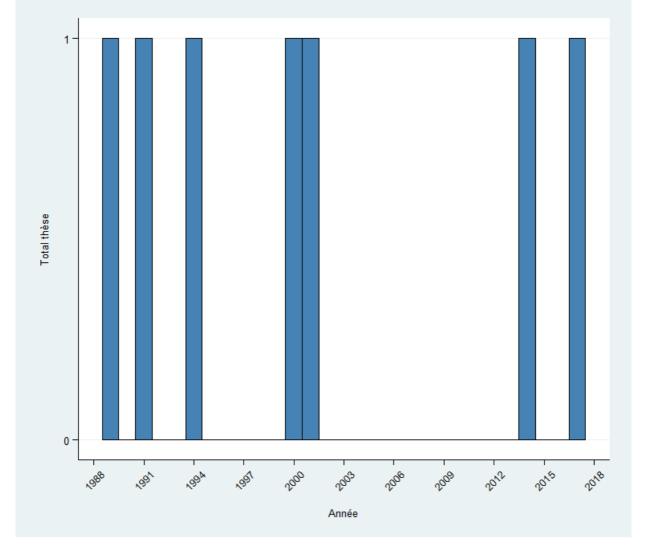
```
## Rows: 1
## Columns: 18
## $ Auteur
                              <int> 1
## $ `Identifiant auteur`
                                <int> 4
## $ Titre
                            <int> 7
## $ `Directeur de these` <int> 7
## $ `Directeur de these (nom prenom)` <int> 7
## $ `Identifiant directeur` <int> 7
## $ `Etablissement de soutenance` <int> 7
## $ `Identifiant etablissement` <int> 7
## $ Discipline
                              <int> 7
## $ Statut
                             <int> 1
## $ `Date de premiere inscription en doctorat` <int> 1
## $ `Date de soutenance` <int> 7
## $ Year
                             <int> 7
## $ `Langue de la these`
                            <int> 2
## $ `Identifiant de la these`
                                <int> 7
## $ `Accessible en ligne`
                                <int> 2
## $ `Publication dans theses.fr`
                                  <int> 3
## $ `Mise a jour dans theses.fr`
                                    <int> 5
```

3.2.2 Visualisation des données manquantes

```
these_cecile_martin %>%
vis_miss() +
scale_y_continuous(labels = comma) +
theme(axis.text.x = element_text(angle = 90))
```



3.2.3 Exploration des données



```
# Filtrage sur l'Identifiant auteur "81323557"

these_cecile_martin %>%

filter(`Identifiant auteur` == "81323557") %>%

ggplot(aes(x = Year)) +

geom_bar(binwidth = 1, fill = "steelblue", color = "black") +

scale_x_continuous(breaks = seq(1990, 2002, 1)) +

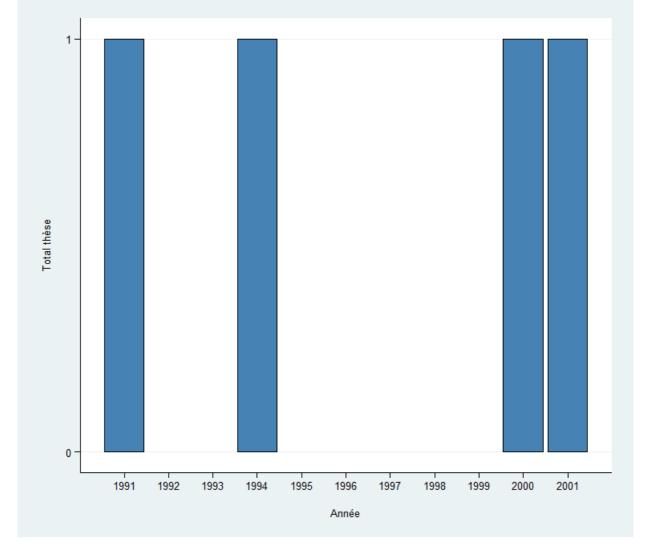
scale_y_continuous(breaks = c(0, 1)) +

labs(x = "\nAnnée",

y = "Total thèse\n") +

theme_stata() +

theme(axis.text.y = element_text(angle = 0))
```



4 Outliers

4.1 Outliers director

4.1.1 Import et préparation des données

```
these_director <- these[!grepl(",", these$`Directeur de these (nom prenom)`), ]
these_director <- these_director[!grepl("@", these_director$`Directeur de these (nom prenom)`), ]

these_director <- these_director %>%
filter(Year > 1983 & Year < 2019) %>%
select(`Directeur de these (nom prenom)`, `Identifiant directeur`) %>%
group_by(`Directeur de these (nom prenom)`) %>%
mutate(total_these_diriger = n())

dim(these_director)
```

```
## [1] 308587 3
```

```
n_distinct(these_director$`Directeur de these (nom prenom)`)
```

```
## [1] 66148
```

```
n_distinct(these_director$`ldentifiant directeur`)
```

4.1.2 Méthodes de différent moyen de calcul des outliers

```
# Mean and Standard deviation (SD)
## Tmin, Tmax = mean(+-)(k*sd), k = 3
Tmin_msd <- mean(these_director$total_these_diriger) - (3 * sd(these_director$total_these_diriger))
Tmax_msd <- mean(these_director$total_these_diriger) + ( 3 * sd(these_director$total_these_diriger))
msd <- which(these_director$total_these_diriger < Tmin_msd |
                              these_director$total_these_diriger > Tmax_msd)
msd_outliers <- these_director[msd,]
min(msd_outliers$total_these_diriger)
## [1] 131
max(msd_outliers$total_these_diriger)
## [1] 711
# Median and Median Absolute Deviation (MAD)
## MAD = b * median(|xi - median(x)|), b = 1.4826 for normal distribution
## Tmin, Tmax = median(+-)(k*MAD), k = 3
med <- median(these_director$total_these_diriger)
abs_med <- abs(these_director$total_these_diriger - med)
mad <- 1.4826 * median(abs_med)
Tmin_mad <- med - (3 * mad)
Tmax mad <- med + (3 * mad)
mad <- which(these_director$total_these_diriger < Tmin_mad |
         these_director$total_these_diriger > Tmax_mad)
mad_outliers <- these_director[mad,]
min(mad_outliers$total_these_diriger)
## [1] 36
max(mad outliers$total these diriger)
## [1] 711
# Interquartile Range (IQR)
## Tmin = Q1 - (c * IQR) c = 1.5(mild)
## Tmax = Q3 + (c * IQR) c = 1.5(mild)
summary(these_director)
## Directeur de these (nom prenom) Identifiant directeur total_these_diriger
```

```
## Length:308587
                          Length:308587
                                            Min. : 1.00
## Class :character
                          Class :character
                                           1st Qu.: 4.00
## Mode :character
                          Mode :character Median : 9.00
                                 Mean : 16.21
##
##
                                 3rd Qu.: 18.00
##
                                 Max. :711.00
```

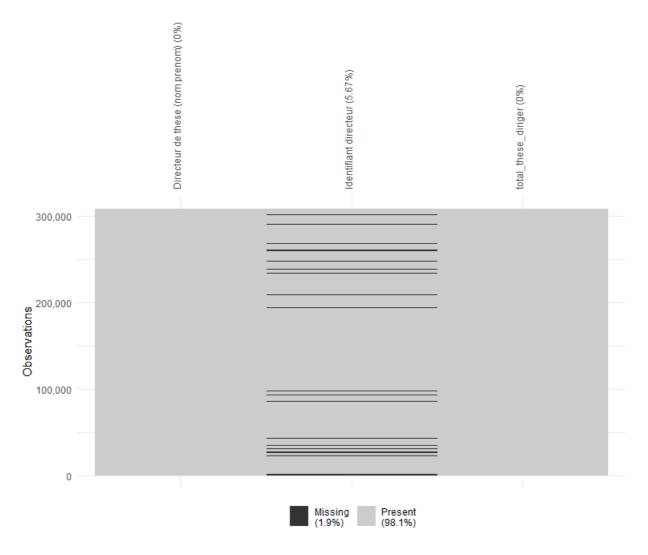
```
IQR(these_director$total_these_diriger)
## [1] 14
Tmin_iqr_mild <- 4 - (1.5 * 14)
Tmax_iqr_mild <- 18 + (1.5 * 14)
iqr_mild <- which(these_director$total_these_diriger < Tmin_iqr_mild |</pre>
         these_director$total_these_diriger > Tmax_iqr_mild)
iqr_mild_outliers <- these_director[iqr_mild,]</pre>
min(iqr_mild_outliers$total_these_diriger)
## [1] 40
max(iqr_mild_outliers$total_these_diriger)
## [1] 711
## Tmin = Q1 - (c * IQR) c = 3(extreme)
## Tmax = Q3 + (c * IQR) c = 3(extreme)
Tmin_iqr_ext <- 4 - (3 * 14)
Tmax_iqr_ext <- 18 + (3 * 14)
iqr_ext <- which(these_director$total_these_diriger < Tmin_iqr_ext |</pre>
             these_director$total_these_diriger > Tmax_iqr_ext)
iqr_ext_outliers <- these_director[iqr_ext,]</pre>
min(iqr_ext_outliers$total_these_diriger)
## [1] 61
```

max(iqr_ext_outliers\$total_these_diriger)

[1] 711

4.1.3 Visualisation des données manquantes

```
these_director %>% vis_miss(warn_large_data = FALSE) +
scale_y_continuous(labels = comma) +
theme(axis.text.x = element_text(angle = 90))
```



4.1.4 Recherches des outliers

```
these_director %>%

ggplot(aes(total_these_diriger)) +

geom_histogram(binwidth = 3, fill = "steelblue", color = "Black") +

geom_vline(aes(xintercept = median(total_these_diriger)), color = "yellow3", size = 1) +

scale_y_continuous(labels = comma) +

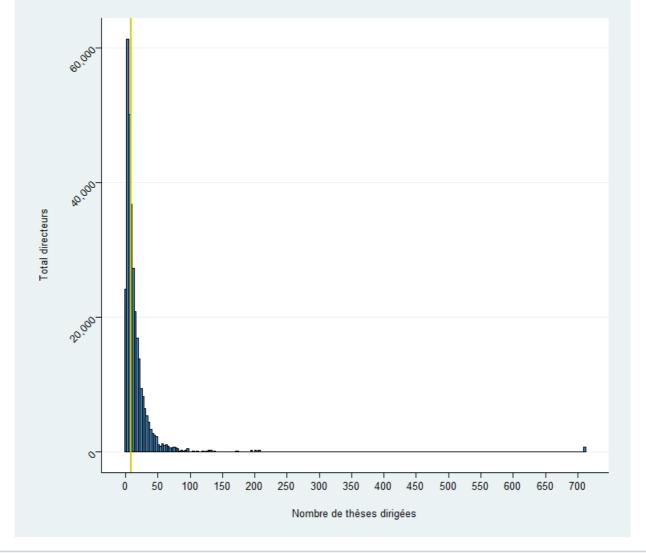
labs(x = "\nNombre de thèses dirigées",

y = "Total directeurs\n") +

scale_x_continuous(breaks = seq(0, 800, 50)) +

theme_stata() +

theme(axis.text.y = element_text(angle = 45))
```



```
these_director %>%

ggplot(aes(total_these_diriger)) +

geom_histogram(binwidth = 1, fill = "steelblue", color = "Black") +

geom_vline(aes(xintercept = median(total_these_diriger)), color = "yellow3", size = 1) +

scale_x_continuous(limits = c(0, 220), breaks = seq(0, 220, 10)) +

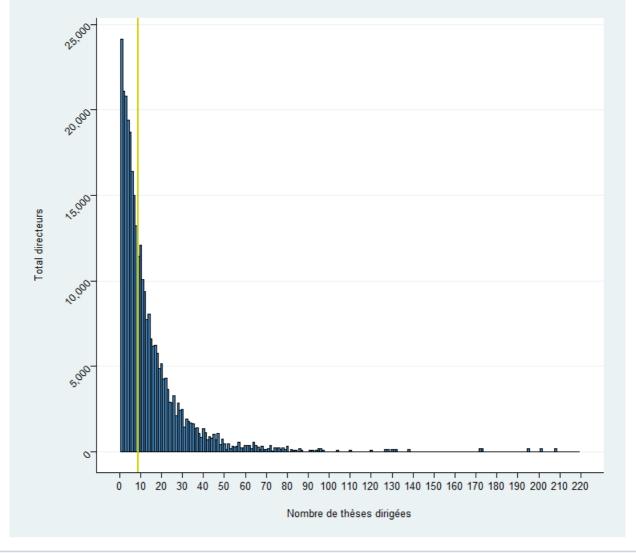
scale_y_continuous(labels = comma) +

labs(x = "\nNombre de thèses dirigées",

y = "Total directeurs\n") +

theme_stata() +

theme(axis.text.y = element_text(angle = 45))
```



```
these_director %>%

ggplot(aes(total_these_diriger)) +

geom_histogram(binwidth = 1, fill = "steelblue", color = "Black") +

geom_vline(aes(xintercept = min(iqr_mild_outliers$total_these_diriger)), color = "yellow3", size = 1) +

scale_x_continuous(limits = c(0, 220), breaks = seq(0, 220, 10)) +

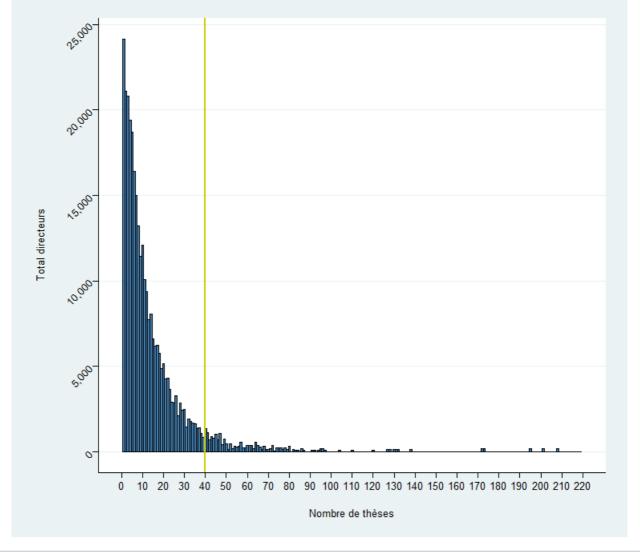
scale_y_continuous(labels = comma) +

labs(x = "\nNombre de thèses",

y = "Total directeurs\n") +

theme_stata() +

theme(axis.text.y = element_text(angle = 45))
```



```
these_director %>%

filter(total_these_diriger >= 40) %>%

ggplot(aes(total_these_diriger)) +

geom_histogram(binwidth = 5, fill = "steelblue", color = "Black") +

scale_x_continuous(breaks = seq(40, 720, 30)) +

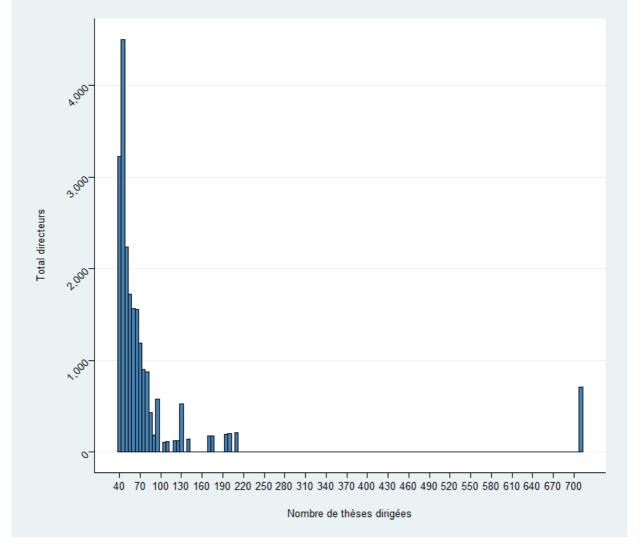
scale_y_continuous(labels = comma) +

labs(x = "\nNombre de thèses dirigées",

y = "Total directeurs\n") +

theme_stata() +

theme(axis.text.y = element_text(angle = 45))
```



4.1.5 Analyse des outliers

[1] 20068 3

n_distinct(these_director_outliers\$`Directeur de these (nom prenom)`)

[1] 367

n_distinct(these_director_outliers\$`ldentifiant directeur`)

[1] 447

glimpse(these_director_outliers)

```
## Rows: 20,068

## Columns: 3

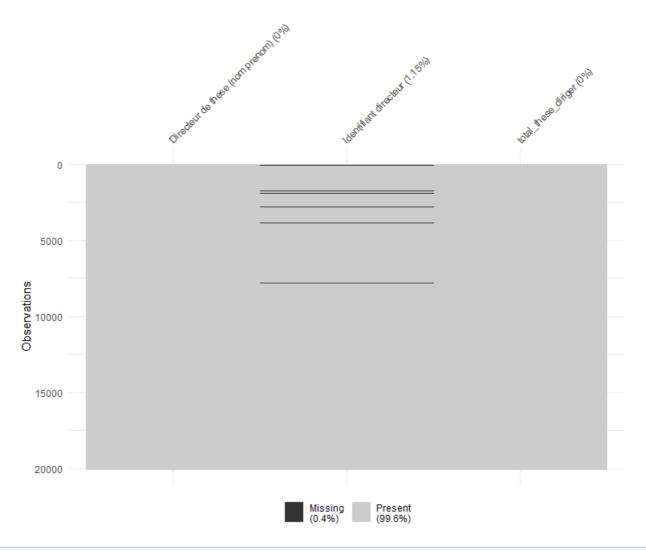
## Groups: Directeur de these (nom prenom) [367]

## $ `Directeur de these (nom prenom)` <chr> "Jouve Edmond", "Dekeuwer-Defossez F~

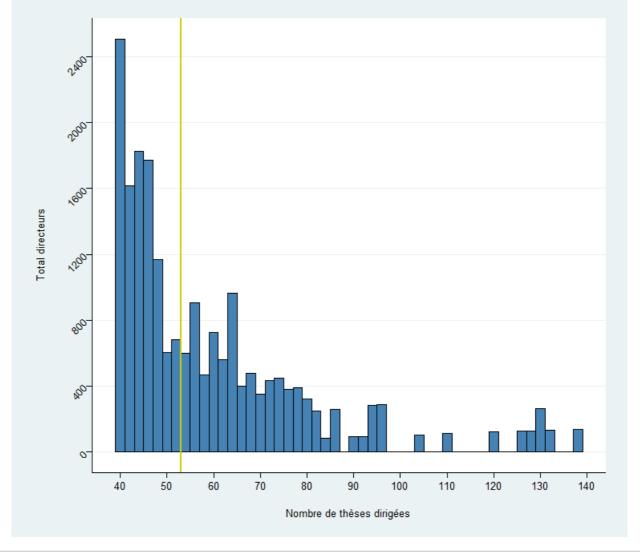
## $ `Identifiant directeur` <chr> "26941848", "26818094", "26941848", ~

## $ total_these_diriger <int> 46, 44, 46, 41, 59, 44, 75, 75, 43, ~
```

```
vis_miss(these_director_outliers)
```



```
ggplot(these_director_outliers, aes(total_these_diriger)) +
geom_histogram(binwidth = 2, fill = "steelblue", color = "Black") +
geom_vline(aes(xintercept = median(total_these_diriger)), color = "yellow3", size = 1) +
labs(x = "\nNombre de thèses dirigées",
    y = "Total directeurs\n") +
scale_x_continuous(breaks = seq(40, 140, 10)) +
scale_y_continuous(breaks = seq(0, 2600, 400)) +
theme_stata() +
theme(axis.text.y = element_text(angle = 45))
```



```
# total theses >= 140 & <= 240
these_director_outliers_middle <- these_director %>% filter(total_these_diriger >= 140 & total_these_diriger <= 240)
dim(these_director_outliers_middle)
```

```
## [1] 949 3
```

n_distinct(these_director_outliers_middle\$`Directeur de these (nom prenom)`)

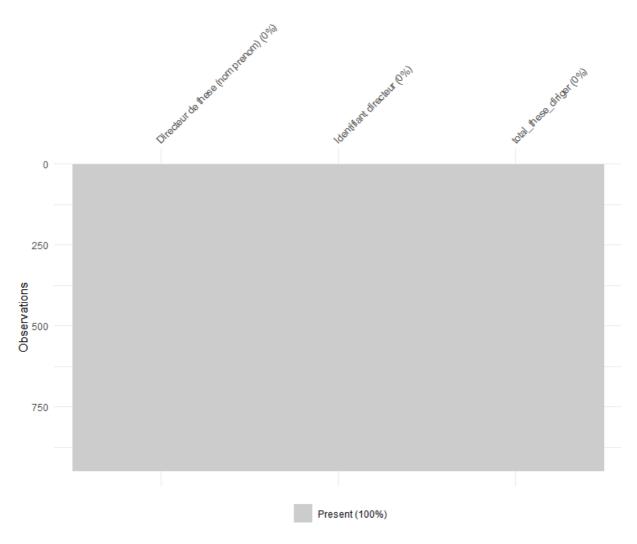
[1] 5

n_distinct(these_director_outliers_middle\$`ldentifiant directeur`)

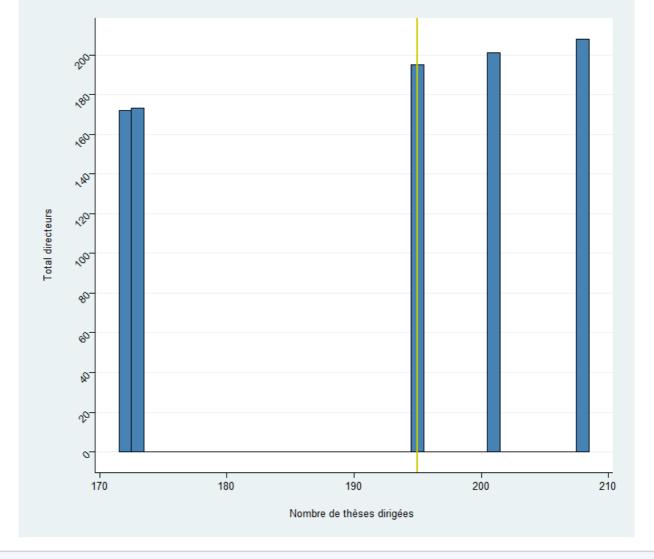
[1] 7

glimpse(these_director_outliers_middle)

```
## Rows: 949
## Columns: 3
## Groups: Directeur de these (nom prenom) [5]
## $ `Directeur de these (nom prenom)` <chr> "Blanc Francois-Paul", "Blanc Franco~
## $ `Identifiant directeur` <chr> "26730774", "26730774", "26756625", ~
## $ total_these_diriger <int> 201, 201, 195, 172, 195, 195, 195, 195, 195, 1>
```



```
ggplot(these_director_outliers_middle, aes(total_these_diriger)) +
geom_histogram(binwidth = 1, fill = "steelblue", color = "Black") +
geom_vline(aes(xintercept = median(total_these_diriger)), color = "yellow3", size = 1) +
labs(x = "\nNombre de thèses dirigées ",
    y = "Total directeurs\n") +
scale_x_continuous(breaks = seq(170, 210, 10)) +
scale_y_continuous(breaks = seq(0, 200, 20)) +
theme_stata() +
theme(axis.text.y = element_text(angle = 45))
```



 $\label{these} \begin{tabular}{ll} \# \ Total \ theses > 700. \\ these_director_outliers_big <- \ these_director \%>\% \ filter(total_these_diriger > 250) \\ dim(these_director_outliers_big) \\ \end{tabular}$

[1] 711 3

n_distinct(these_director_outliers_big\$`Directeur de these (nom prenom)`)

[1] 1

unique(these_director_outliers_big\$`Directeur de these (nom prenom)`)

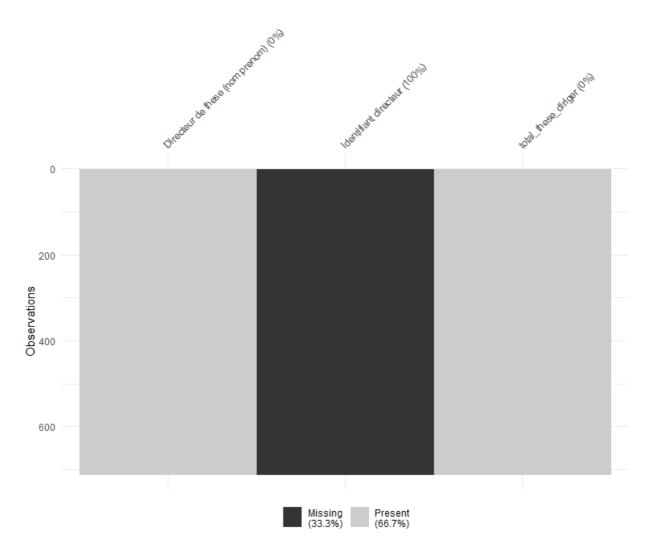
[1] "Directeur de these inconnu"

n_distinct(these_director_outliers_big\$`ldentifiant directeur`)

[1] 1

glimpse(these_director_outliers_big)

```
vis_miss(these_director_outliers_big)
```



5 Résultats préliminaires

5.1 Langues

5.1.1 Import et préparation des données

```
these_langue <- these
these_langue <- rename(these_langue, Langue = `Langue de la these`)
these_langue <- these_langue %>%

mutate(Langue = as.factor(case_when(
    is.na(Langue) ~ "NA",
    Langue == "fr" ~ "Français",
    Langue == "en" ~ "Anglais",
    Langue == "enfr" | Langue == "fren" ~ "Bilingue",
    TRUE ~ "Autres")))
levels(these_langue$Langue)
```

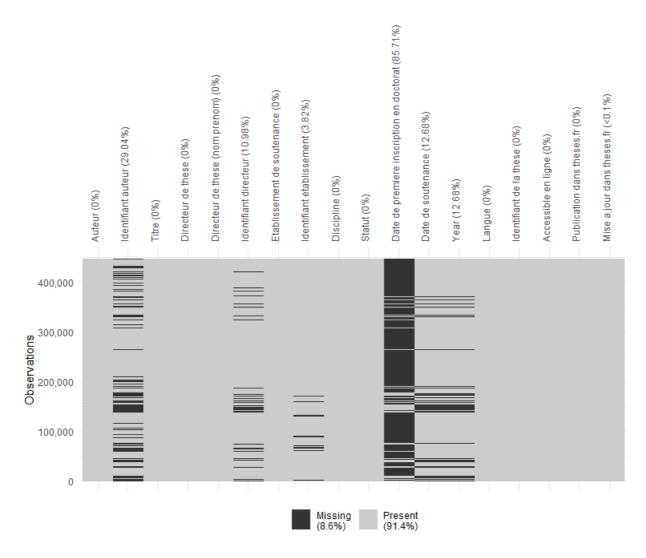
```
Identifiant auteur Titre
## Auteur
                                        Directeur de these
## Length:447644 Length:447644 Length:447644 Length:447644
## Class:character Class:character Class:character Class:character
## Mode :character Mode :character Mode :character Mode :character
##
##
##
##
## Directeur de these (nom prenom) Identifiant directeur
## Length:447644 Length:447644
## Class :character Class :character
## Mode :character
##
                        Mode :character
##
##
##
##
## Etablissement de soutenance Identifiant etablissement Discipline
                    Length:447644
## Length:447644
                                        Length:447644
## Class :character
                       Class :character
                                          Class:character
## Mode :character
                     ##
##
##
##
##
     Statut Date de premiere inscription en doctorat
## enCours: 66329 Length: 447644
## soutenue:381315 Class:character
##
       Mode :character
##
##
##
##
## Date de soutenance Year
                                 Langue
                                           Identifiant de la these
## Min. :1971-01-01 Min. :1971 Anglais: 30942 Length:447644
## 1st Qu.:1994-01-01 1st Qu.:1994 Autres : 3164 Class :character
## Median: 2004-01-01 Median: 2004 Bilingue: 15369 Mode: character
## Mean :2003-06-08 Mean :2003 Français:334404
## 3rd Qu.:2012-06-25 3rd Qu.:2012 NA : 63765
## Max. :2020-07-07 Max. :2020
## NA's :56746 NA's :56746
## Accessible en ligne Publication dans theses.fr Mise a jour dans theses.fr
## non:347341 Min. :2006-04-13 Min. :2010-10-12
## oui:100303 1st Qu.:2013-05-24 1st Qu.:2019-04-08
    Median :2013-05-24 Median :2020-02-26
##
            Mean :2014-11-09 Mean :2019-06-30
##
             3rd Qu.:2016-07-11 3rd Qu.:2020-03-08
##
              Max. :2020-07-08 Max. :2020-07-08
##
##
                            NA's :177
```

```
these_langue %>%
summarise(across(everything(), n_distinct)) %>%
glimpse()
```

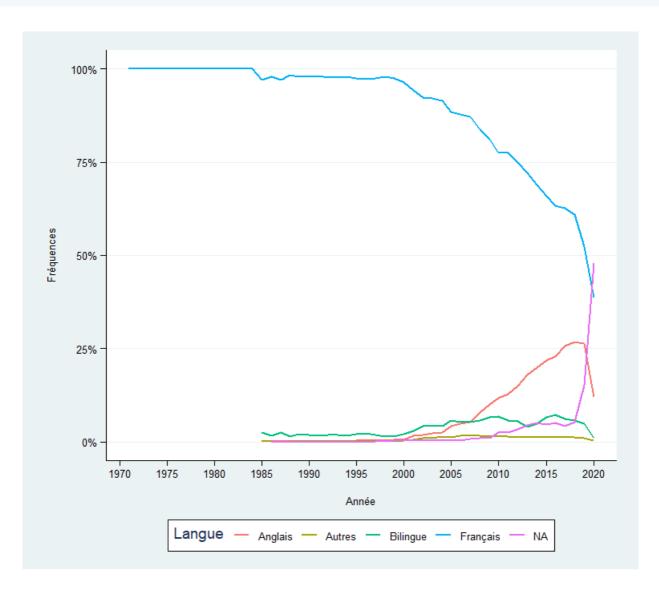
```
## Rows: 1
## Columns: 18
## $ Auteur
                                  <int> 430277
                                     <int> 313775
## $ `Identifiant auteur`
## $ Titre
                                 <int> 446815
## $ `Directeur de these`
                                      <int> 159019
## $ `Directeur de these (nom prenom)`
                                            <int> 159021
## $ `Identifiant directeur`
                                     <int> 98907
## $ `Etablissement de soutenance`
                                           <int> 568
## $ 'Identifiant etablissement'
                                        <int> 573
## $ Discipline
                                  <int> 24263
## $ Statut
                                 <int> 2
## $ `Date de premiere inscription en doctorat` <int> 4010
## $ `Date de soutenance`
                                       <int> 3992
## $ Year
                                 <int> 45
## $ Langue
                                   <int> 5
## $ `Identifiant de la these`
                                      <int> 447572
## $ `Accessible en ligne`
                                      <int> 2
## $ `Publication dans theses.fr`
                                        <int> 2765
## $ `Mise a jour dans theses.fr`
                                         <int> 2634
```

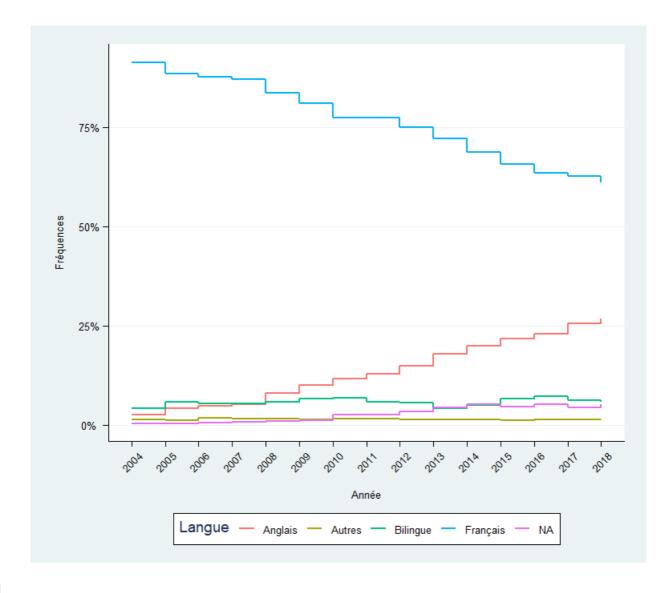
5.1.2 Données manquantes

```
vis_miss(these_langue, warn_large_data = FALSE)+
scale_y_continuous(labels = comma) +
theme(axis.text.x = element_text(angle = 90))
```



```
# Fréquence des langues.
these_langue_count_year <- these_langue %>%
 select(Year) %>%
 count(Year) %>%
 rename(total\_year = n)
these_langue_count_langue <- these_langue %>%
 count(Year, Langue) %>%
 rename(langue_count = n)
these_langue_fulljoin <- full_join(these_langue_count_year,
        these_langue_count_langue,
        by = "Year") %>%
 mutate(freq = langue_count / total_year)
# Jeu de données entier
these_langue_fulljoin %>%
ggplot(aes(Year, freq, color = Langue)) +
 geom\_line(size = 1) +
 scale_x_continuous(breaks = seq(1970, 2020, 5)) +
 scale_y_continuous(labels = percent_format()) +
 labs(x = "\nAnnée",
   y = "Fréquences\n") +
 theme_stata() +
 theme(axis.text.y = element\_text(angle = 0))
```





6 SQL

```
business <- read_csv("jeux_de_donnees/business.csv")

glimpse(business)
```

7 Travail en bonus

7.1 Heatmap des données manquantes

7.1.1 Import et préparation des données

```
these_missing_heatmap <- these %>%

select(Year, `Langue de la these`, `Identifiant etablissement`, `Identifiant directeur`,

`Identifiant auteur`, `Date de soutenance`, `Date de premiere inscription en doctorat`,

Statut) %>%

group_by(Statut) %>%

miss_var_summary()

these_missing_heatmap$pct_miss <- round(these_missing_heatmap$pct_miss, 1)
```

7.1.2 Visualisations

```
these_missing_heatmap %>%

ggplot(aes(Statut, variable, fill = pct_miss)) +

geom_tile(color = "black") +

geom_text(aes(label = pct_miss), color = "black", size = 4) +

labs(y = "Variables\n") +

scale_fill_gradient2(low = "#075AFF",

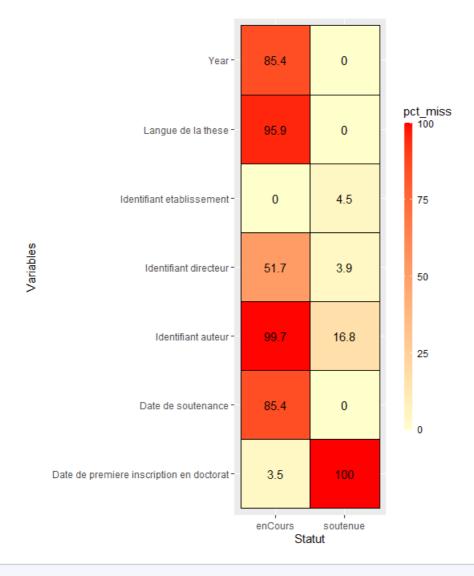
mid = "#FFFCC",

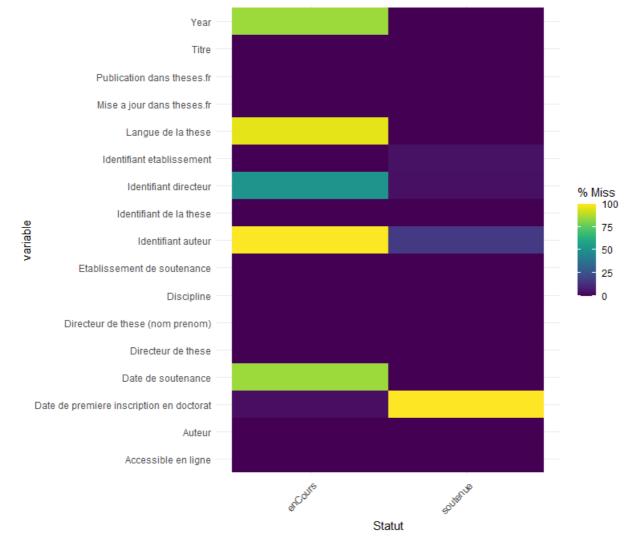
high = "#FF0000") +

guides(fill = guide_colourbar(barwidth = 0.5,

barheight = 20)) +

coord_fixed()
```





Les deux heatmap représente la même chose mais montre deux moyens de le faire diffèrement.

7.2 Problème Genre/Discipline/Langue

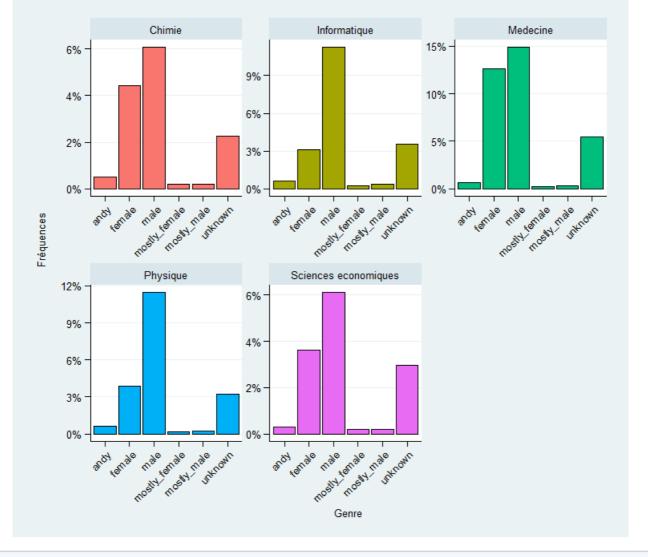
7.2.1 Problème Genre/Discipline import et préparation des données PhD_v2_gender

```
these_gender <- as_tibble(read_csv("jeux_de_donnees/PhD_v2_gender.csv"))
these_gender <- subset(these_gender, select = -c(...1))
these gender$`Date de premiere inscription en doctorat` <- dmy(these gender$`Date de premiere inscription en doctorat`)
these_gender$`Date de soutenance` <- dmy(these_gender$`Date de soutenance`)
these _gender$`Publication dans theses.fr` <- dmy(these _gender$`Publication dans theses.fr`)
these_gender$`Mise a jour dans theses.fr` <- dmy(these_gender$`Mise a jour dans theses.fr`)
these_gender$Statut <- as.factor(these_gender$Statut)
these_gender$`Langue de la these` <- as.factor(these_gender$`Langue de la these`)
these gender$'Accessible en ligne' <- as.factor(these gender$'Accessible en ligne')
these_gender$`Identifiant directeur` <- na_if(these_gender$`Identifiant directeur`,"na")
these_gender$gender <- as.factor(these_gender$gender)</pre>
these_gender$Gender <- these_gender$gender
these_gender %>%
 subset(select = -c(gender)) %>%
 summarise(across(everything(), n_distinct)) %>%
 glimpse()
```

```
## Rows: 1
## Columns: 21
## $ Auteur
                         <int> 430277
## $ `Identifiant auteur`
                         <int> 313775
## $ Titre
                         <int> 446815
## $ `Directeur de these` <int> 159019
## $ `Directeur de these (nom prenom)` <int> 159021
## $ `Identifiant directeur` <int> 98907
## $ `Etablissement de soutenance` <int> 568
## $ `Identifiant etablissement` <int> 573
## $ Discipline
                         <int> 24263
## $ Statut
                         <int> 2
## $ `Date de premiere inscription en doctorat` <int> 4010
## $ `Date de soutenance` <int> 3992
## $ Year
                        <int> 45
## $ `Langue de la these`
                         <int> 206
<int> 44920
## $ First name
                           <int> 237706
## $ Last name
## $ Gender
                          <int> 6
```

7.2.2 Visualisations

```
# Selection des top 5 disciplines
these_gender_top_5_discipline <- these_gender %>%
 select(Discipline, Gender) %>%
 count(Discipline, sort = TRUE) %>%
 slice(1:5) %>%
 subset(select = -c(n)) %>%
these_gender_top_5_discipline <- these_gender %>%
 filter(Discipline %in% these_gender_top_5_discipline)
# Visualisations
these_gender_top_5_discipline %>%
 ggplot(aes(Gender, after_stat(count/sum(count)), fill = Discipline)) +
 geom_bar( position = "dodge", color = "black") +
 facet_wrap( ~ Discipline, scales = "free") +
 scale_y_continuous(labels = percent_format()) +
 labs(x = "Genre",
    y = "Fréquences\n") +
 theme_stata() +
 theme(legend.position = "none",
    axis.text.x = element_text(angle = 45, hjust = 1),
    strip.text.x = element_text(size = 10),
    axis.text.y = element_text(angle = 0))
```



```
these_gender_top_5_discipline %>%
 ggplot(aes(Gender, after_stat(count/sum(count)), fill = Discipline, by = Gender)) +
 geom_bar( position = "fill", color = "black") +
 geom_text(stat = "prop", position = position_fill(.5),
       colour = "white", fontface = "bold", size = 3.5) +
 scale_y_continuous(labels = percent_format()) +
 labs(x = "Genre",
    y = "Proportions \n") +
 theme_stata() +
 theme(legend.position = "bottom",
     legend.key.size = unit(0.3, 'cm'),
     legend.key.height = unit(0.3, 'cm'),
     legend.key.width = unit(0.3, 'cm'),
     legend.title = element_text(size=14),
     legend.text = element_text(size=10),
     axis.text.y = element_text(angle = 0))
```



```
these_gender_top_5_discipline %>%

ggplot(aes(Gender, after_stat(count/sum(count)), fill = Discipline)) +

geom_bar(position = "dodge", color = "black") +

scale_y_continuous(labels = percent_format()) +

labs(x = "Genre",

y = "Fréquences\n") +

theme_stata() +

theme(legend.position = "bottom",

legend.key.size = unit(0.3, 'cm'),

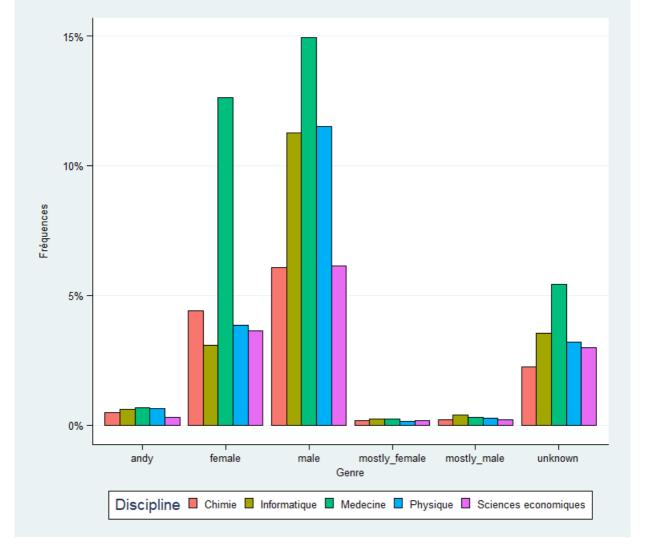
legend.key.height = unit(0.3, 'cm'),

legend.key.width = unit(0.3, 'cm'),

legend.title = element_text(size=14),

legend.text = element_text(size=10),

axis.text.y = element_text(angle = 0))
```



7.2.3 Problème Genre/Discipline import et préparation des données PhD_v3

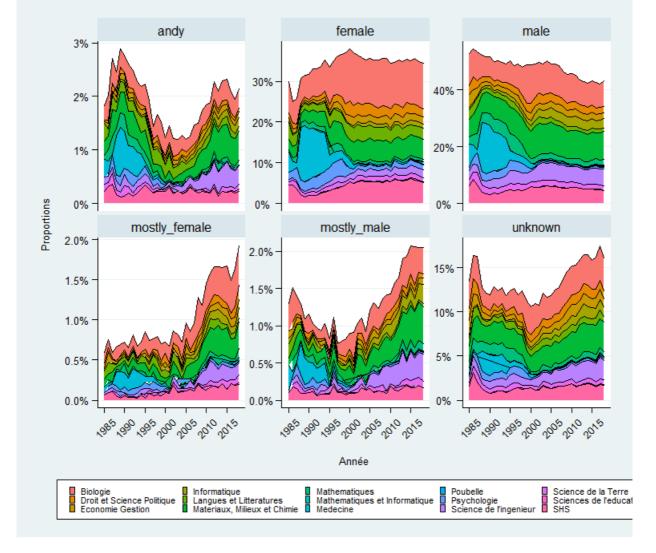
```
these v3 <- as tibble(read_csv("jeux_de_donnees/PhD_v3.csv"))
these_v3 <- subset(these_v3, select = -c(...1))
these_v3$`Date de premiere inscription en doctorat` <- dmy(these_v3$`Date de premiere inscription en doctorat`)
these v3$`Date de soutenance` <- dmy(these v3$`Date de soutenance`)
these_v3$`Publication dans theses.fr` <- dmy(these_v3$`Publication dans theses.fr`)
these_v3$`Mise a jour dans theses.fr` <- dmy(these_v3$`Mise a jour dans theses.fr`)
these_v3$Statut <- as.factor(these_v3$Statut)
these v3$`Langue de la these` <- as.factor(these v3$`Langue de la these`)
these_v3$`Accessible en ligne` <- as.factor(these_v3$`Accessible en ligne`)
these_v3$`ldentifiant directeur` <- na_if(these_v3$`ldentifiant directeur`,"na")
these_v3$Genre <- as.factor(these_v3$Genre)
these_v3 <- rename(these_v3, Discipline_prediction = `Discipline_prAcdi`)
these_v3$Discipline_prediction <- as.factor(these_v3$Discipline_prediction)
\textbf{levels} (\textbf{these\_v3\$Discipline\_prediction}) = = \textbf{"Math$\tilde{A}@matiques"} < - \textbf{"Mathematiques"} = \textbf{"Math$\tilde{A}@matiques"} < - \textbf{"Mathematiques"} = \textbf{"Math$\tilde{A}@matiques"} 
levels(these v3$Discipline prediction)[levels(these v3$Discipline prediction) == "Science de l'ingÃ@nieur" ] <- "Science de l'ingenieur"
these_v3 %>%
    summarise(across(everything(), n_distinct)) %>%
    glimpse()
```

```
## Rows: 1
## Columns: 22
## $ Auteur
                          <int> 430272
## $ `Identifiant auteur`
                          <int> 313772
## $ Titre
                          <int> 446812
## $ `Directeur de these` <int> 159018
## $ `Directeur de these (nom prenom)` <int> 159020
## $ `Identifiant directeur` <int> 98906
## $ `Etablissement de soutenance` <int> 568
## $ `Identifiant etablissement` <int> 573
                          <int> 24262
## $ Discipline
## $ Statut
                          <int> 2
## $ `Date de premiere inscription en doctorat` <int> 4010
## $ `Date de soutenance` <int> 3992
                         <int> 45
## $ Year
## $ `Langue de la these`
                          <int> 206
## $ Genre
                          <int> 6
## $ Genre <int> 6
## $ etablissement_rec <int> 111
## $ Langue_rec
                             <int> 5
```

7.2.4 Préparation des tables intermédiaires

7.2.5 Visualisation

```
these_genre_discipline_full %>%
 ggplot(aes(Year, freq, fill = Discipline_prediction)) +
 geom_area(color = "black") +
 facet_wrap( ~ Genre, scales = "free_y") +
 scale_x continuous(breaks = seq(1985, 2020, 5)) +
 scale_y_continuous(labels = percent_format()) +
 labs(x = "\nAnnée",
    y = "Proportions \n") +
 theme_stata() +
 theme(axis.text.x = element_text(angle = 45,
                      vjust = 0.5),
    axis.text.y = element\_text(angle = 0,
                    hjust = 0.5),
    legend.key.size = unit(0.2, "cm"),
    legend.text = element_text(size = '8'),
    legend.title = element_blank())
```



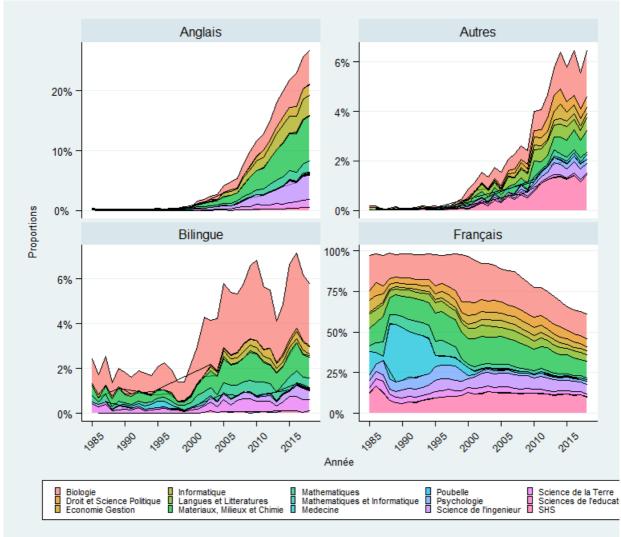
7.2.6 Problème Langue/Discipline import et préparation des données PhD_v3

```
these_v3_langue <- these_v3
these_v3_langue <- rename(these_v3_langue, Langue = `Langue de la these`)
these_v3_langue <- these_v3_langue %>%
mutate(Langue = as.factor(case_when(
    is.na(Langue) ~ "NA",
    Langue == "fr" ~ "Français",
    Langue == "en" ~ "Anglais",
    Langue == "enfr" | Langue == "fren" ~ "Bilingue",
    TRUE ~ "Autres")))
```

7.2.7 Préparation des tables intermédiaires

7.2.8 Visualisation

```
these_genre_discipline_full %>%
 ggplot(aes(Year, freq, fill = Discipline_prediction)) +
 geom_area(color = "black", alpha = 0.7) +
 facet_wrap( ~ Langue , scales = "free_y") +
 scale_x_continuous(breaks = seq(1985, 2020, 5)) +
 scale y continuous(labels = percent format()) +
 labs(x = "Année",
    y = "Proportions \n") +
 theme_stata() +
 theme(axis.text.x = element_text(angle = 45,
                      vjust = 0.5),
    axis.text.y = element\_text(angle = 0,
                     hjust = 0.5),
    legend.key.size = unit(0.2, "cm"),
    legend.text = element_text(size = '8'),
    legend.title = element_blank())
```



7.3 Webscraping

```
langue <- c("fr", "en", "es")
numero_page <- seq(0, 500, 10)
numero_page_langue <- seq(0, 300, 10)
thesis_webscraping_info <- tibble()
thesis_webscraping_pdf <- tibble()
thesis_webscraping_langue <- tibble()
for (page result in numero page) {
link_infos <- paste0("https://theses.fr/fr/?q=&fq=dateSoutenance:[1965-01-01T23:59:59Z%2BTO%2B2022-12-31T23:59:59Z]&checkedfacets=&start=",
      nage_result "&sort=none&status=&access=&nrevision=&filtrenersonne=&zone1=titreRAs&val1=&on1=AND&zone2=auteurs&val2=&on2=AND
```

```
pages_infos <- read_html(link_infos)
 Titre <- pages infos %>% html nodes("h2 a") %>% html text2() %>% str to lower() %>%
  str_to_sentence()
 Auteur <- pages_infos %>% html_nodes("#resultat p") %>% html_text2() %>%
  str_split("\r", n = 2) \%>\% map_chr(1) \%>\% sub(".*? ", "", .)
 Discipline <- pages_infos %>% html_nodes(".domaine h5:nth-child(1)") %>% html_text2()
 Directeur <- pages_infos %>% html_nodes("#resultat p") %>% html_text2() %>%
  str\_split("\r", n = 3) \%>\%
  map_chr(3) %>% sub(".*? ", "", .) %>% str_replace(" et de \r", ",") %>%
  str_split("\\r") %>% map_chr(1)
 Etablissment <- pages_infos %>% html_nodes("#resultat p") %>% html_text2() %>%
  str\_split("\r", n = 3) \%>\%
  map\_chr(3) \%>\% \ sub(".*?", "", .) \%>\% \ str\_replace("\ et\ de\ \"", ",") \%>\%
  str_split("\\r") %>% map_chr(2) %>% str_remove(" - ")
 Statut <- pages infos %>% html nodes("div.statusThese img") %>% html attr("title")
 Date_soutenance_ymd <- pages_infos %>% html_nodes("br+ h5") %>% html_text2() %>%
  str_remove("En préparation depuis le ") %>% str_sub(13, 22) %>% dmy()
 str_remove_all("En préparation depuis le ") %>% str_remove_all("Soutenue le ") %>%
  str_sub(12, 16) %>% as.Date(as.character(), format = "%Y") %>% year()
 Date_inscription <- pages_infos %>% html_nodes("br+ h5") %>% html_text2() %>%
  str_sub(25, 35) %>% dmy()
 thesis_webscraping_info <- rbind(thesis_webscraping_info, tibble(Auteur, Titre, Discipline, Directeur,
                       Etablissment, Statut, Date_inscription,
                       Date_soutenance_ymd, Date_soutenance_y))
for (page_pdf in numero_page) {
 link_pdf <- paste0("https://theses.fr/fr/?q=&fq=dateSoutenance:[1965-01-01T23:59:59Z%2BTO%2B2022-12-31T23:59:59Z]&checkedfacets=&start=",paste0"
 pages_pdf <- read_html(link_pdf)</pre>
 Link_to_pdf <- pages_pdf %>% html_nodes(".arrondi-10x a") %>% html_attr("href") %>%
  paste0("theses.fr", .)
 Auteur <- pages_pdf %>% html_nodes("#resultat p") %>% html_text2() %>%
  str_split("\\r", n = 2) %>% map_chr(1) %>% sub(".*? ", "", .)
 thesis_webscraping_pdf <- rbind(thesis_webscraping_pdf, tibble(Auteur, Link_to_pdf))
for(Lg in langue){
 for (npl in numero_page_langue) {
  link_langue <- paste0("https://theses.fr/fr/?q=&fg=dateSoutenance:[1965-01-01T23:59:59Z%2BTO%2B2022-12-31T23:59:59Z]&checkedfacets=langue
  pages_langue <- read_html(link_langue)
  Auteur <- pages_langue %>% html_nodes("#resultat p") %>% html_text2() %>%
   str_split("\\r", n = 2) %>% map_chr(1) %>% sub(".*? ", "", .)
  Langue <- Lg
  thesis_webscraping_langue <- rbind(thesis_webscraping_langue, tibble(Auteur, Langue))
```

```
thesis webscraping <- left join(thesis webscraping info, thesis webscraping pdf, by = "Auteur")
thesis webscraping <- left join(thesis webscraping, thesis webscraping langue, by = "Auteur")
thesis_webscraping <- thesis_webscraping %>% mutate(Statut = case_when(Statut == "thèse en cours de préparation" ~ "en_cours", Statut == "thèse s
glimpse(thesis_webscraping)
## Rows: 519
## Columns: 11
## $ Auteur
            <chr> "Matthias Pautard ", "Mohamed Amine Khelif ", "Dam~
## $ Titre
             <chr> "Simulation de la balistique intérieure de mortier~
## $ Directeur
             <chr> "Christian Chauveau", "Olivier Romain", "Colette D~
## $ Etablissment <chr> "Orléans ", "CY Cergy Paris Université ", "Valenci~
         <chr> "en_cours", "en_cours", "en_cours", "en_cours", "e~
## $ Statut
## $ Date inscription <date> 2020-11-09, NA, 2022-04-28, 2022-04-28, 2018-12-0~
## $ Date_soutenance_y <dbl> NA, NA, NA, NA, NA, 2009, 2006, 2003, 2006, 2009, ~
## $ Langue
               <chr> NA, "fr", NA, NA, NA, "fr", "fr", "fr", "fr", NA, ~
summary(thesis_webscraping)
   Auteur
                       Discipline
              Titre
                                  Directeur
## Length:519
            Length:519
                          Length:519 Length:519
## Class :character Class :character Class :character
## Mode :character Mode :character Mode :character
##
##
##
## Etablissment
               Statut
                        Date inscription
## Length:519 Length:519 Min. :2007-10-01
## Class:character Class:character 1st Qu.:2021-07-13
## Mode :character Mode :character Median :2021-10-01
##
                   Mean :2021-03-25
##
                   3rd Qu.:2021-12-28
##
                   Max. :2022-05-16
                   NA's :193
## Date_soutenance_ymd Date_soutenance_y Link_to_pdf
## Min. :2013-07-08 Min. :1985 Length:519 Length:519
## 1st Qu.:2021-06-21 1st Qu.:1986 Class :character Class :character
## Median: 2021-12-14 Median: 1997 Mode: character Mode: character
## Mean :2021-05-14 Mean :1998
## 3rd Qu.:2022-02-18 3rd Qu.:2008
```

head(thesis_webscraping)

NA's :435

Max. :2022-04-19 Max. :2012

NA's :410